



基于元学习的物理信息神经网络 损失函数发现方法

Psaros et al. (2022) Meta-learning PINN loss functions 复现与改进

丁佩东 李广志

2026 年 6 月





目录

目录

第一部分：研究背景

- PINN 基础与挑战
- 损失函数设计的重要性
- 元学习动机

第二部分：方法论

- First-Order MAML 框架
- 损失函数参数化
- 双层优化算法

第三部分：实验设计

- Burgers 方程验证问题
- 多任务分布构造
- 模型架构与超参数

第四部分：结果与总结

- 元训练与权重演化
- 元测试对比分析
- 改进亮点与展望



PINN 基础

物理信息神经网络

核心思想

物理信息神经网络 (PINN) 将 PDE 残差、边界条件和初始条件编码为损失函数, 利用神经网络自动微分求解正问题和反问题。

PINN 工作流程

PINN 总损失函数

$$\mathcal{L}(\theta) = \lambda_{IC}\mathcal{L}_{IC} + \lambda_{BC}\mathcal{L}_{BC} + \lambda_{PDE}\mathcal{L}_{PDE}$$

其中 λ 为各分量的**权重超参数**。

1. 神经网络 $\hat{u}(x, t; \theta)$ 近似解
2. 自动微分计算 PDE 残差
3. 最小化数据 + 物理约束损失
4. 反向传播更新网络参数



损失函数的挑战

为什么需要元学习？

传统方法的困境

- MSE 对所有残差一视同仁
- 不同 PDE 任务需不同权重
- 手动调参耗时费力
- 经验权重非最优
- 无法适应任务特异性

元学习解决思路

- 从一类相关 PDE 任务中学习
- 自动发现最优损失权重
- 跨任务泛化到新参数
- 减少手工调参依赖
- 可能超越 MSE 性能

核心问题

如何自动学习损失函数，使其在**新 PDE 任务**上表现更优？



元学习损失函数

Psaros et al. (2022) 核心贡献

关键创新

提出一种**元学习框架**，通过双层优化从 PDE 任务分布中自动学习参数化的损失函数，替代手工设计的固定 MSE 损失。

方法要点

- **任务分布**：同一类 PDE 的不同参数实例
- **可学习损失**： $\lambda = \exp(w)$ ， w 为可学习对数权重
- **双层优化**：内循环适配 + 外循环元更新
- **First-Order 近似**：降低计算复杂度

预期收益

- 自动发现任务自适应的损失权重
- 泛化到未见过的 PDE 参数
- 减少手动超参数调优
- 为更复杂损失函数奠定框架



First-Order MAML 框架

双层优化概览

内循环（任务适配）

- 对每个任务 τ_i ，固定损失权重 ϕ ，微调 PINN 参数 θ
- $K = 5$ 步 SGD，学习率 $\alpha = 10^{-3}$

$$\theta_{\tau}^* = \arg \min_{\theta} \mathcal{L}_{train}(\theta; \phi, \tau_i)$$

外循环（元更新）

- 在验证集上评估适配后模型，更新损失权重 ϕ
- `stop_gradient` 断开二阶路径

$$\phi^* = \arg \min_{\phi} \sum_i \mathcal{L}_{val}(\text{sg}(\theta_{\tau_i}^*); \phi, \tau_i)$$

First-Order MAML 关键设计

`stop_gradient` 将梯度从 4 阶降至 1 阶，大幅降低计算开销，保留元学习核心能力。



损失函数参数化

标量权重 + LAL + FFN

方案一：标量权重

$\mathcal{L} =$

$\exp(w_u)\mathcal{L}_{data} + \exp(w_f)\mathcal{L}_{PDE}$

- 2 个可学习参数
- $\lambda = \exp(w)$ 保证非负

方案二：LAL

$\ell_{\alpha,c}(r)$: 自适应损失族

- 4 参数 $(\alpha_u, c_u, \alpha_f, c_f)$
- $\alpha \rightarrow 2$: MSE, $\alpha \rightarrow 1$: L1

2,40,40,1 无偏置

方案三：FFN

$\mathcal{L} = \text{FFN}_{\eta}(u_{pred}, u_{true})$

- 1720 参数, Softplus

标量 $\rightarrow$ LAL $\rightarrow$ FFN: 2 参数 $\rightarrow$ 4 参数 $\rightarrow$ 1720 参数损失函数



训练流程

三阶段流水线

1. 任务数据生成

- 对每个 ν 生成 BC/IC 点和内部配点, 80/20 分割

2. 元训练 (外循环 $\times K=5$ 内循环适配)

- 每任务执行 $K=5$ 步 SGD 适配, 外循环 Adam 更新损失参数

3. 元测试 (未见任务, 从头训练)

- 固定学习到的损失函数, Adam 训练 1000 轮 vs 均匀权重基线



验证问题：一维 Burgers 方程

验证问题与实验设计

Burgers 方程

$$u_t + uu_x = \nu u_{xx}, \quad x \in [-1, 1], t \in [0, 1]$$

$$u(x, 0) = -\sin(\pi x), \quad u(-1, t) = u(1, t) = 0$$

任务分布 $p(\nu)$

为什么选择 Burgers 方程？

- 具有非线性对流项 $u \cdot u_x$
- 小 ν 时形成激波
- 对 PINN 训练具有挑战性
- 经典基准测试问题

类型	ν 取值
训练	$\{0.005, 0.008, 0.01, 0.015, 0.02\}/\pi$
测试	$0.012/\pi$ (未见过的中间值)

测试任务 ν 位于训练区间中间，严格检验内插泛化能力。



参考解与数据配置

验证问题与实验设计

参考解：FD-RK4 方法

- 四阶 Runge-Kutta + 中心差分
- 自动 CFL 条件检查与网格细化
- 对所有 ν 值数值稳定
- 初始条件误差 $< 10^{-16}$
- 边界条件误差 $< 10^{-16}$

数据配置（每个任务）

数据类型	点数
边界条件	2×200
初始条件	400
内部配点	2000
训练/验证	80%/20%



模型架构与超参数

验证问题与实验设计

PINN 网络结构

层	维度	激活
输入	2	-
隐藏 1-4	50	Tanh
输出	1	线性

总参数量: $\sim 7,801$

元学习超参数

参数	值
内循环 lr α	10^{-3}
内循环步数 K	5
外循环 lr β	$10^{-2} \rightarrow 10^{-3}$
基模型 lr	10^{-4}
元训练轮数	200
λ 范围	[0.05, 20.1]

学习率调度: 余弦退火

$$\beta_t = \beta_{\min} + \frac{1}{2}(\beta_0 - \beta_{\min})(1 + \cos(\pi t/M))$$



元训练过程

三种参数化方法对比

标量权重 (200 轮)

- λ_{data} : $1.0 \rightarrow 0.772$, λ_{PDE} : 稳定在 ~ 1.0
- 元损失 $0.269 \rightarrow 0.206$

LAL (1000 轮, Adam)

- α_u : $2.01 \rightarrow 1.77$, c_u : $0.71 \rightarrow 1.40$
- α_f : $2.01 \rightarrow 1.98$, c_f : $0.71 \rightarrow 1.43$
- 元损失 $0.287 \rightarrow 0.072$

FFN (500 轮, Adam lr=1e-4)

- $|W_1|$: $0.048 \rightarrow 0.044$, $|W_2|$: $0.030 \rightarrow 0.029$
- $|W_3|$: $0.068 \rightarrow 0.071$
- 元损失 $1.79 \rightarrow 1.43$ (含 Eq.28 正则化)

参数演化分析

- LAL: $\alpha_u \rightarrow 1.77$ 趋向 L1, $\alpha_f \approx 1.98$ 保持 MSE
- FFN: 1720 参数给予高灵活性, 正则化周期性非零

跨参数化一致性

三种方法一致收敛至**偏重 PDE 残差**的策略——
验证元学习发现的稳健性。



元测试结果

FFN + LAL vs 多基线损失函数

方法	L2 相对误差	数据损失	PDE 残差
FFN (ours)	0.999	2.56×10^{-1}	2.17×10^{-5}
LAL (ours)	0.710	9.64×10^{-2}	3.67×10^{-2}
MSE	0.532	4.23×10^{-2}	8.57×10^{-2}
L1	0.794	1.49×10^{-1}	4.14×10^{-3}
Cauchy	0.647	8.13×10^{-2}	3.37×10^{-2}

FFN 分析

- PDE 残差降低 99.97% (极端偏重物理)
- 但 $L2=0.999$, 完全忽略数据拟合
- 1720 参数在 5 个训练任务上过拟合


综合发现

- 参数容量 $\uparrow$, PDE 偏好程度 $\uparrow$
- $\text{FFN}(1720) > \text{LAL}(4) > \text{标量}(2)$ 极端度
- MSE 在 Burgers 上接近最优 ($L2=0.532$)



实验结果：综合分析面板

实验结果与分析



LAL 结果 (左) : (a) 元训练损失 (b) 参数演化 (c) 测试损失对比 (d-e) 解快照 (f)L2 误差 FFN 结果 (右) :
(a) 元训练损失 (b) 权重范数 (c-f) 同上



可视化分析

LAL + FFN 综合面板详解

LAL 面板 (左图)

- (a) 元训练损失曲线 (LAL, 1000 轮)
- (b) LAL 参数 (α , c) 演化
- (c) 4 种损失函数训练曲线对比
- (d) $t = 0.25$ 时 LAL vs MSE 解对比
- (e) $t = 0.5$ 时 LAL vs MSE 解对比
- (f) 4 方法 L2 误差柱状图

FFN 面板 (右图)

- (a) 元训练损失 (FFN, 500 轮)
- (b) FFN 权重范数 $|W_1|$, $|W_2|$, $|W_3|$ 演化
- (c-f) 同上 4 方法对比

关键观察

- LAL: $\alpha_u \rightarrow 1.77$ (趋 L1), $\alpha_f \approx 1.98$ (MSE)
- FFN: 权重收缩但 $|W_3|$ 略增
- FFN PDE 残差极低 ($2.17e-5$) 但数据拟合退化
- MSE 在所有设置下 L2 误差最优

输出位置

`./imgs/improved_result.png` (LAL),

`./imgs/ffn_result.png` (FFN)



主要改进（相对原始简化版）

论文级完整复现

改进项	原版本	改进版
PDE 方程	Heat (缺少 $u \cdot u_x$)	完整 Burgers 方程
参考解	不匹配的解析解	MOL-RK45 (数值稳定)
损失参数化	固定权重	标量 + LAL + FFN (2/4/1720 参数)
元学习	单任务训练	5 任务 + FO-MAML + Adam
基线对比	无	MSE + L1 + Cauchy 三基线
正则化	无	Eq.28 (FFN), Prop. 1 (LAL)

完成度

已实现论文全部三种损失参数化方案：标量权重、LAL (Section 3.4.1.1)、FFN (Section 3.4.1.2)。



消融实验

改进亮点与消融实验

内循环步数影响

K	测试 L2	时间
1	较差	快
3	中等	较快
5	最优	适中
10	相似	慢

$K = 5$ 提供最佳精度-效率平衡。

学习率策略对比

策略	收敛质量
固定 10^{-2}	快但不稳定
固定 10^{-3}	慢且欠收敛
余弦退火	前快后稳

余弦退火兼顾探索与收敛。

5 个训练任务 → 提供充足的元学习信号，同时避免过拟合



总结与贡献

总结与展望

1. 完整复现论文三种参数化方案

实现 Psaros et al. (2022) 全部损失参数化：标量权重 (2 参数)、LAL (4 参数)、FFN (1720 参数)

2. 跨参数化一致性发现

三种方法一致发现偏重 PDE 策略 (FFN: -99.97%, 标量: -55%, LAL: -49%), 验证发现的稳健性

3. 参数容量效应揭示

参数越多 $\rightarrow$ PDE 偏好越极端 $\rightarrow$ 过拟合风险越大

4. 多基线损失对比

MSE vs L1 vs Cauchy vs LAL vs FFN 五路对比, 系统揭示损失选择的影响

5. 数值稳定性改进

MOL-RK45 参考解、FFN 预训练、Xavier 初始化、梯度函数预定义



未来工作方向

总结与展望

短期优化

- 调优 FFN Eq.28 正则化强度，遏制过拟合
- 增加元训练至 10000 轮（论文设置）
- 扩展到 2D PDE (Navier-Stokes)
- 更多训练任务增强统计显著性

长期方向

- 高维 PDE 问题 (100D+)
- 反应扩散方程、波方程等
- 与自适应采样策略结合
- 在线元学习与架构搜索

核心愿景

将元学习引入 PINN 损失函数设计，减少对手动超参数调优的依赖，实现更智能、更自动化的物理信息机器学习。



主要参考文献

参考文献

元学习与 PINN

1. Psaros A F, et al. “Meta-learning PINN loss functions.” J. Comput. Phys., 2022.
2. Raissi M, et al. “Physics-informed neural networks.” J. Comput. Phys., 2019.
3. Finn C, et al. “Model-agnostic meta-learning for fast adaptation of deep networks.” ICML, 2017.

Burgers 方程与数值方法

4. Bateman H. “Some recent researches on the motion of fluids.” Mon. Weather Rev., 1915.
5. Burgers J M. “A mathematical model illustrating the theory of turbulence.” Adv. Appl. Mech., 1948.
6. Cole J D. “On a quasi-linear parabolic equation occurring in aerodynamics.” Q. Appl. Math., 1951.



谢谢！

欢迎提问与讨论

- First-Order MAML · Burgers 方程 · MindSpore 复现
 - 5 训练任务 · 余弦退火 · FD-RK4 参考解