

基于元学习的物理信息神经网络损失函数发现方法研究

摘要

本报告旨在探讨并验证一种用于物理信息神经网络（Physics-Informed Neural Networks, PINN）的元学习损失函数方法。PINN作为一种求解偏微分方程（PDEs）的强大工具，其性能高度依赖于损失函数的设计。传统上，均方误差（MSE）被广泛使用，但其并非最优选择，且手动调参耗时费力。本研究基于Psaros等人（2022）的工作，实现了三种损失函数参数化方法：（1）**标量权重**—学习数据与PDE损失的对数权重（ w_u, w_f ）；（2）**LAL (Learned Adaptive Loss)**—学习自适应损失函数 $\ell_{\alpha,c}(r)$ 的4个参数；（3）**FFN (Feed-Forward Network)**—使用 [2,40,40,1] 无偏置 ReLU+Softplus 网络学习任意损失函数形状（1720参数）。三种方法均采用First-Order MAML元学习算法，通过内循环适配（K步梯度下降）与外循环更新损失参数的双层优化，自动发现数据损失与PDE残差损失之间的最优平衡。我们利用MindSpore框架进行了完整实现，并以一维Burgers方程（含非线性对流项 $u \cdot u_x$ ）为例进行验证，使用Method of Lines + 迎风格式 + RK45自适应步长方法提供精确参考解。实验结果表明，元学习一致地发现降低PDE残差的策略（PDE损失降低49-55%），但在本实验设置下整体L2精度未超越MSE基线。我们进一步对比了L1和Cauchy等多种基线损失函数，分析了元学习损失函数的泛化行为。

1. 引言

物理信息神经网络（PINN）通过将PDE残差、边界条件和初始条件编码为损失函数，利用神经网络的自动微分能力求解正问题和反问题。然而，PINN的训练过程充满挑战，损失函数的形式、各损失分量的权重等超参数选择对模型的收敛速度和解的精度具有决定性影响。标准MSE损失函数对所有残差一视同仁，无法适应不同任务的特异性。

为此，Psaros等人（2022）提出了一种元学习PINN损失函数的方法。其核心思想是：假设存在一类相关的PDE任务（例如，由不同参数控制的同一类方程），通过在一组训练任务上“学习如何学习”，得到一个优化的损失函数，该损失函数能够使得PINN在求解新的、同分布的任务时表现更佳。本报告根据该论文提供的算法，使用MindSpore框架进行了改进复现，实现了以下关键改进：

- 正确求解含非线性对流项的Burgers方程；
- 通过Method of Lines + 迎风格式 + RK45自适应步长方法提供精确参考解；
- 实现真正的多任务元学习（First-Order MAML），在不同粘度系数 ν 的任务分布上学习损失权重，并在未见过的 ν 值上验证泛化能力。

2. 方法论

2.1 PINN基础

PINN通过神经网络 $\hat{u}(x, t; \theta)$ 近似PDE的解 $u(x, t)$ 。总损失函数通常包括：

- 数据损失**：监督模型拟合初始条件(IC)和边界条件(BC)的已知值。
- PDE残差损失**：确保模型在整个域内满足物理定律。

总损失的通用形式为：

$$\mathcal{L}(\theta) = \lambda_{IC}\mathcal{L}_{IC} + \lambda_{BC}\mathcal{L}_{BC} + \lambda_{PDE}\mathcal{L}_{PDE}$$

其中， λ 为各分量的权重。传统方法中，这些权重被固定为经验值。

2.2 元学习损失函数框架

本研究采纳的元学习方法旨在学习一个参数化的损失函数，而不仅仅是固定权重。其核心是一个双层优化问题，实现为**First-Order MAML**（Model-Agnostic Meta-Learning）变体。

内层优化（任务适配）：针对从任务分布 $p(\nu)$ 中采样的每个具体PDE任务 τ_i （由不同粘度系数 ν 定义），使用当前参数化的损失函数 ℓ_ϕ 来更新PINN的参数 θ 。

$$\theta_\tau^*(\phi) = \arg \min_{\theta} \mathbb{E}_{(x,t) \sim \mathcal{D}_\tau} [\ell_\phi(\hat{u}_\theta(x, t), u_\tau(x, t))]$$

其中， $\phi = (w_u, w_f)$ 是损失函数对数权重的可学习参数， $\mathcal{D}_\tau$ 是任务 τ 的训练数据（包括配点和边界/初始条件）。

外层优化：在所有训练任务上，评估由内层优化得到的PINN参数 θ^* 的性能，并据此更新损失函数的参数 ϕ 。

$$\phi^* = \arg \min_{\phi} \mathbb{E}_{\tau \sim p(\nu)} [\mathcal{L}_{\text{val}}(\text{stop_gradient}(\theta^*_{\tau}(\phi)), \phi)]$$

关键设计：为避免四阶梯度计算，采用**First-Order MAML近似**——在对验证损失求 ϕ 的梯度时，通过 `stop_gradient` 操作断开适配后模型参数 θ^* 的梯度链路，仅保留 ϕ 对验证损失的**直接影响**路径。这大大降低了计算复杂度，同时保留了元学习的核心能力。

2.3 损失函数参数化

我们实现了两种损失函数参数化方案：

方案一：标量权重（简化版）

$$\lambda_{IC} = \exp(w_{IC}), \quad \lambda_{BC} = \exp(w_{BC}), \quad \lambda_{PDE} = \exp(w_{PDE})$$

其中 $\{w_{IC}, w_{BC}, w_{PDE}\}$ 是在元学习过程中更新的对数权重参数。进一步简化为两个权重： λ_u （合并BC/IC）和 λ_f （PDE残差）。

方案二：LAL (Learned Adaptive Loss) — 论文 Section 3.4.1.1

$$\ell_{\alpha,c}(r) = \frac{|\alpha-2|}{\alpha} \left(\left(\frac{r^2/c^2}{|\alpha-2|} + 1 \right)^{\alpha/2} - 1 \right)$$

其中 r 为残差 ($u_{pred} - u_{true}$ 或 PDE残差)， $\alpha \in \mathbb{R}$ 控制损失形状， $c > 0$ 为尺度参数。该参数化具有两个关键优势 (Proposition 1)：

1. **最优平稳条件：**在最优参数 θ^* 处， $\nabla_{\theta} \mathbb{E}[\ell(\hat{u}_{\theta}(x), u)] = \nabla_{\theta} \mathbb{E}[(\hat{u}_{\theta}(x) - u)^2]$
2. **MSE关系条件：**损失地形与MSE地形相关，保持梯度效率

初始化 $\alpha = 2.01, c = 1/\sqrt{2}$ 使 LAL 近似于 MSE（当 $\alpha \rightarrow 2$ 时）。总损失为：

$$\mathcal{L}(\theta) = \text{mean}(\ell_{\alpha_u, c_u}(u_{pred} - u_{true})) + \text{mean}(\ell_{\alpha_f, c_f}(\mathcal{R}_{PDE}))$$

可学习参数为 $\phi = (\alpha_u, \log c_u, \alpha_f, \log c_f)$ （对数参数化保证 $c > 0$ ）。

方案三：FFN (Feed-Forward Network) — 论文 Section 3.4.1.2

使用一个小型神经网络作为损失函数：输入 (u_{pred}, u_{true}) 或 $(r, 0)$ （其中 r 为 PDE 残差），输出逐点损失值。网络结构为 $[2, 40, 40, 1]$ ，无偏置，激活函数为 ReLU + ReLU + Softplus（保证非负输出），使用 Xavier 均匀初始化，总计 1720 个可学习参数。该参数化可以学习任意非凸的损失函数形状。

为保证学习到的损失函数具有良好的数值性质，在元训练中施加 **Eq. 28 正则化**（两项）：

1. **最优平稳条件：** $\mathbb{E}_q[\|\nabla_q \text{FFN}(q, q)\|^2]$ — 在零残差处梯度应为零
2. **MSE 关系条件：** $\mathbb{E}_{q \neq q'}[\max(0, s - \|\nabla_q \text{FFN}(q, q')\|^2)]$ — 非零残差处梯度的范数应不小于 $s = 0.01$

正则化系数为 0.01，采用批量梯度计算（2次 `ms.grad` 调用，避免逐样本循环）。

为加速收敛，FFN 首先在合成 MSE 数据 ($\text{FFN}(d, 0) \approx d^2$) 上预训练 200 步 Adam (lr=1e-3)，使损失函数初始化近似 MSE。

2.4 训练流程

我们的实现遵循以下训练流程：

1. **元训练 (First-Order MAML)：**
 - 从训练任务分布中采样所有任务（不同 ν 值）。
 - 对于每个任务，使用当前对数损失权重 (w_u, w_f) ，通过 $K = 5$ 步梯度下降（SGD）内循环适配PINN参数 θ 。
 - 对适配后的参数应用 `stop_gradient` 断开二阶梯度路径。
 - 计算适配后模型在验证集上的损失对 (w_u, w_f) 的直接梯度，并累加平均。
 - 使用累加梯度更新 (w_u, w_f) （外循环）。

- 同时，在所有任务的训练数据上直接优化基模型参数 θ 。

2. 元测试：

- 在元训练完成后，固定学习到的损失权重 $\lambda_u = \exp(w_u)$, $\lambda_f = \exp(w_f)$ 。
- 在一个全新的、未见过的PDE任务（不同 ν 值）上从头开始训练一个PINN。
- 使用Adam优化器训练1000轮，与均匀权重（ $\lambda_u = \lambda_f = 1$ ）基线进行对比。

3. 实验设计与结果

3.1 任务设置：Burgers方程与参考解

我们选择了一维Burgers方程作为验证问题，这是一个典型的非线性PDE，具有激波特性，对PINN的训练构成挑战。方程定义如下：

$$\begin{aligned} u_t + uu_x &= \nu u_{xx}, \quad x \in [-1, 1], t \in [0, 1] \\ u(x, 0) &= -\sin(\pi x) \\ u(-1, t) &= u(1, t) = 0 \end{aligned}$$

其中，粘度系数 ν 在不同任务中取值不同。**关键纠正：**原简化版本错误地遗漏了非线性对流项 uu_x ，实际求解的是热方程（Heat Equation）。本改进版本严格求解完整的Burgers方程。

参考解方法：使用Method of Lines（MOL）方法求解Burgers方程。空间离散采用迎风格式（对流项， $u \cdot u_x$ 方向自适应差分）和中心差分（扩散项， νu_{xx} ），时间积分使用SciPy `solve_ivp` 的RK45自适应步长方法。迎风格式基于局部流速 u 的符号自动选择前向或后向差分，有效处理激波区域；RK45自适应步长自动满足稳定性约束，无需手动CFL检查。边界条件在 $x = \pm 1$ 处严格强制 $u = 0$ 。该参考解用于评估PINN的预测精度。

元学习任务分布：

- 元训练任务：** $\nu \in \{0.005/\pi, 0.008/\pi, 0.01/\pi, 0.015/\pi, 0.02/\pi\}$ （5个不同粘度系数）
- 元测试任务：** $\nu = 0.012/\pi$ （训练中未见过的中间值）

3.2 模型架构与参数

我们使用一个包含4个隐藏层、每层50个神经元、激活函数为Tanh的前馈神经网络作为PINN。元学习阶段：内循环使用SGD（学习率 10^{-3} ，5步），外循环学习率 10^{-2} ，基模型学习率 10^{-4} 。元测试阶段：使用Adam优化器（学习率 10^{-4} ），训练1000个epoch。元学习的目标是在不同 ν 的任务上学习数据损失和PDE残差损失之间的最优权重 $\lambda_u = \exp(w_u)$ 和 $\lambda_f = \exp(w_f)$ 。

3.3 结果分析

3.3.1 标量权重方法

在200轮元训练迭代中，元损失从0.2688下降至0.2060。损失权重从初始均匀值收敛至 $\lambda_u = 0.772$, $\lambda_f = 0.9995$ 。元学习发现降低数据拟合权重、保持PDE残差权重的策略。

3.3.2 LAL 方法

元训练：1000轮迭代（Adam外循环，T=1），LAL参数演化：

- α_u : 2.01 $\rightarrow$ 1.77（趋向L1-like形状）， c_u : 0.71 $\rightarrow$ 1.40
- α_f : 2.01 $\rightarrow$ 1.98（保持MSE-like）， c_f : 0.71 $\rightarrow$ 1.43
- 元损失：0.287 $\rightarrow$ 0.072（外循环有效优化）

3.3.3 FFN 方法

预训练：FFN在合成MSE数据上预训练200步Adam（lr=1e-3），MSE从13.09降至1.21，初始化近似MSE损失函数。

元训练：500轮迭代（Adam外循环，lr=1e-4，T=1，Eq.28正则化coef=0.01，s=0.01），FFN权重RMS范数演化：

- $|W_1|$: 0.0477 $\rightarrow$ 0.0437 (40 $\times$ 2, 输入层权重)
- $|W_2|$: 0.0301 $\rightarrow$ 0.0285 (40 $\times$ 40, 隐藏层权重)
- $|W_3|$: 0.0675 $\rightarrow$ 0.0706 (1 $\times$ 40, 输出层权重)
- 元损失: 1.7855 $\rightarrow$ 1.4265 (正则化项周期性非零, 指示 FFN 偏离 MSE 形状)

元测试 ($\nu = 0.012/\pi$) :

方法	L2 相对误差	数据损失 (MSE)	PDE 残差 (MSE)
FFN (ours)	0.999	2.56×10^{-1}	2.17×10^{-5}
LAL (ours)	0.710	9.64×10^{-2}	3.67×10^{-2}
MSE	0.532	4.23×10^{-2}	8.57×10^{-2}
L1	0.794	1.49×10^{-1}	4.14×10^{-3}
Cauchy	0.647	8.13×10^{-2}	3.37×10^{-2}

3.3.4 综合分析

三种元学习方法（标量权重、LAL、FFN）表现出一致的行为模式：

1. **PDE 残差改善一致**：FFN 降低 99.97% (PDE= 2.17×10^{-5})，标量方法降低 55.5%，LAL 降低 49.3%——元学习稳定地发现偏重物理约束的策略
2. **参数容量与极端程度正相关**：FFN（1720 参数）最极端地偏重 PDE，几乎完全忽略数据拟合 (L2=0.999)；LAL（4 参数）居中；标量（2 参数）相对温和——更高参数容量可能导致训练分布上的过拟合
3. **数据拟合退化**：三种方法的数据损失均劣于 MSE 基线，导致整体 L2 误差未超越。当前 Eq.28 正则化 (coef=0.01, s=0.01) 对 FFN 的约束力不足
4. **L1 极端案例**：L1 损失使 PDE 残差降至 4.14×10^{-3} ，但数据拟合严重退化 (L2=0.794)，说明极端偏重物理约束不利于整体精度
5. **Cauchy 表现稳健**：Cauchy 损失 (L2=0.647) 是最接近 MSE (0.532) 的替代方案

可能原因：(a) 仅 5 个训练任务，元学习对训练分布过拟合；(b) 内循环仅 5 步 SGD，适配不充分；(c) FFN 500 轮/LAL 1000 轮元训练远少于论文的 10000 轮；(d) 元测试使用 Adam 而内循环使用 SGD，存在优化器不匹配；(e) Burgers 方程上 MSE 已接近最优，高容量参数化导致过度的 PDE 偏好；(f) Eq.28 正则化强度需针对 FFN 高参数容量调优。

可视化输出：

改进版 Notebook 生成包含 6 个子图的综合分析面板：

- (a) 元训练损失曲线（对数坐标）
- (b) 损失权重 λ_u, λ_f 随元训练迭代的演化过程
- (c) 元测试任务上元学习权重 vs 均匀权重的训练损失对比
- (d-e) $t = 0.25$ 和 $t = 0.5$ 时刻的精确解、元学习 PINN、基线 PINN 的三方对比
- (f) L2 误差的柱状图对比

综合结果图保存至 `./imgs/improved_result.png`。

4. 结论与讨论

本研究报告成功复现并改进了元学习在优化PINN损失函数方面的方法。相比原简化版本，改进版的核心贡献包括：

- **主要改进：**

- **正确的PDE实现**：从错误的热方程修正为完整的Burgers方程（含 $u \cdot u_x$ 非线性对流项），并通过Method of Lines + 迎风格式 + RK45自适应步长方法提供精确参考解。
- **LAL + FFN 损失参数化**：实现了论文 Section 3.4.1.1 的 LAL 自适应损失函数（4 参数）和 Section 3.4.1.2 的 FFN 损失网络（[2,40,40,1]，1720 参数，Eq.28 正则化），完成了论文全部三种参数化方案。
- **多基线对比**：在MSE之外增加了L1和Cauchy两种基线损失函数，全面评估元学习损失的性能。
- **论文一致的训练设置**：Adam外循环优化器，T=1任务采样。
- **核心发现**：
 - 三种参数化方法（标量权重、LAL、FFN）一致地学习到偏重PDE残差的策略（FFN: -99.97%, 标量: -55.5%, LAL: -49.3%），验证了元学习发现的策略不是参数化特定的，而是跨参数化稳健的。
 - 参数容量越高（FFN 1720 > LAL 4 > 标量 2），学习到的策略越极端偏重 PDE，表明高容量参数化在有限训练任务上更容易过拟合。Eq.28 正则化（coef=0.01）对 FFN 约束不足。
 - 三种方法的数据拟合精度均下降，导致整体 L2 误差未超越 MSE 基线。在当前实验设置下，MSE 在 Burgers 方程上已接近最优。
 - L1 和 FFN 的极端案例说明：过度强调 PDE 约束会导致数据拟合严重退化，说明平衡的重要性。
- **展望**：
 - **更强 FFN 正则化**：增大 Eq.28 正则化系数或探索论文中的其他正则化策略，遏制 FFN 过拟合
 - **更长元训练**：将迭代数从 500-1000 增至 10000（论文设置），可能改善收敛
 - **更广泛的基准测试**：将该方法应用于更困难的 PDE 问题（如 Navier-Stokes、反应扩散方程）
 - **内循环优化**：探索 Adam 等带记忆优化器在内循环中的改进策略

总之，本项目成功将元学习引入PINN的损失函数设计，实现了从简单标量权重到论文级LAL参数化的完整演进。虽然在本实验设置下未超越MSE基线，但元学习一致地发现了有意义的损失函数结构（偏重物理约束），为更智能、更自动化的物理信息机器学习开辟了道路。